



T.C.

HİTİT ÜNİVERSİTESİ

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

MAKİNE ÖĞRENMESİ DERSİ

**BİREYLERİN OBEZİTE SEVİYESİNİN YAŞAM TARZI VE
DEMOGRAFİK VERİLER KULLANILARAK MAKİNE
ÖĞRENMESİ İLE TAHMİNİ**

PROJE ÖDEVİ RAPORU

Proje Sorumluları:

Ayşe YENİBAĞCI - 234210067

Shafiqullah QASEMİ - 234210001

Safa KAYALAR - 234210044

Dersin Sorumlusu:

Doç. Dr. Ömer Faruk AKMEŞE

Çorum – 2026

1. GİRİŞ VE VERİ KAYNAĞI

Bu projede, bireylerin yaşam tarzı, fiziksel özellikleri ve günlük beslenme alışkanlıkları veri noktaları olarak kullanılarak, obezite risk seviyelerini tespit etmeye yönelik makine öğrenmesi tabanlı bir sınıflandırma sistemi geliştirilmiştir. Obezitenin küresel bir halk sağlığı sorunu haline gelmesi, bu tür proaktif risk tespit mekanizmalarını kritik kılmaktadır. Proje kapsamında çeşitli makine öğrenmesi modelleri (Lojistik Regresyon, KNN, SVM, Rastgele Orman, Karar Ağaçları, Bagging, Extra Trees ve XGBoost) eğitilmiş ve birbirleriyle karşılaştırılmıştır. Sonuçların analiz edilmesiyle, en yüksek başarıyı gösteren algoritma seçilmiş ve uçtan uca çalışabilen, kullanıcı dostu bir Streamlit arayüzü ile desteklenerek son kullanıcının erişimine sunulmuştur.

1.2. Veri Kaynağı ve Yapısı

Kullanılan temel veri seti (veri.csv), toplamda 20.758 satır ve 19 sütundan oluşan zengin bir yapıya sahiptir. Veri seti içerisinde bireylere ait yaş, cinsiyet gibi demografik bilgilerin yanı sıra, fiziksel aktiviteler ve tüketim alışkanlıkları (su tüketimi, ana öğün sayısı, alkol ve sebze tüketim sıklığı vb.) ölçümlenmiştir. Çalışmanın hedef değişkeni (target variable) bireylerin obezite seviyesini belirten NObeyesdad kolonudur.

1.3. Öznitelikler

Sistemde modele girdi olarak sağlanan temel öznitelikler şunlardır:

- Demografik ve Fiziksel: Gender (Cinsiyet), Age (Yaş), Height (Boy), Weight (Kilo). Boy ve kilo verisi kullanılarak analiz aşamasında Vücut Kitle İndeksi (BMI) hesaplanmıştır.
- Alışkanlıklar ve Yaşam Tarzı: FAVC (Yüksek kalorili yiyecek tüketimi), FCVC (Sebze tüketim sıklığı), NCP (Günlük öğün sayısı), CAEC (Öğün arası yeme alışkanlığı), SMOKE (Sigara kullanımı), CH2O (Günlük su tüketimi).
- Aktivite Düzeyi: SCC (Kalori takibi), FAF (Fiziksel aktivite sıklığı), TUE (Teknoloji kullanım süresi), CALC (Alkol tüketimi), MTRANS (Ulaşım türü).
- Hedef Değişken (Target): Toplam 7 sınıftan (Yetersiz Kilo, Normal Kilo, Fazla Kilo Tip 1, Fazla Kilo Tip 2, Obezite Tip 1, Obezite Tip 2, Obezite Tip 3) oluşan NObeyesdad sütunudur.

2. VERİ ÖN İŞLEME VE KEŞİFSEL VERİ ANALİZİ


Veri setinin algoritmalar tarafından en yüksek verimle kullanılabilmesi için bir dizi ön işleme ve dönüşüm adımı uygulanmıştır.

2.1. Veri Ön İşleme (Preprocessing)

Özellik mühendisliği (Feature Engineering) kapsamında, doğrudan boy ve kilo kullanmak yerine bu iki metriktan türetilen BMI (Vücut Kitle İndeksi) özneliği oluşturulmuştur ($BMI = \text{Weight} / (\text{Height} ** 2)$). Bu işlemin ardından, modelin aşırı öğrenmesini engellemek ve gürültüyü azaltmak için id, Height ve Weight kolonları veri setinden çıkarılmıştır. Kategorik verilerin sayısal modellere uygun hale getirilmesi için pandas kütüphanesinin get_dummies() fonksiyonu ile One-Hot Encoding işlemi gerçekleştirilmiştir. Hedef değişken olan sınıf etiketleri ise Scikit-Learn LabelEncoder yardımıyla matematiksel formata dönüştürülmüştür.


2.2. Keşifsel Veri Analizi ve Ölçeklendirme

Keşifsel veri analizi sırasında hedef değişkenin dağılımları ve BMI değerlerinin frekansları detaylıca incelenmiştir. Modellerin daha stabil çalışabilmesi ve optimizasyon algoritmalarının (örneğin Gradient Descent) daha hızlı yakınsaması adına giriş özellikleri StandardScaler ile ölçeklendirilmiş, böylelikle farklı birimlere sahip olan veriler (yaş, öğün sayısı, BMI) aynı düzleme (standart normal dağılım) getirilmiştir.



Grafik 1 Veri setindeki obezite sınıflarının kişi sayısına göre dağılımı

Yukarıdaki grafikte veri setimizde yer alan 7 farklı obezite ve kilo kategorisinin dağılımı görülmektedir. Sınıfların kendi içlerinde nispeten dengeli bir dağılım sergilemesi, makine öğrenmesi modelimizin eğitim aşamasında belirli bir sınıfa karşı aşırı eğilim (bias) göstermesini engelleyen olumlu bir durumdur.



Grafik 2 Katılımcıların Vücut Kitle İndeksi (BMI) değerlerinin frekans dağılımı

Boy ve kilo kullanılarak türetilen BMI özelliğinin genel dağılımı incelendiğinde, verilerin ağırlıklı olarak 25 ile 35 aralığında (Fazla Kilolu ve Obezite Tip 1) yoğunlaştığı görülmektedir. Bu dağılım, modelin ayrıştırıcı özellik olarak BMI'ı neden bu kadar yoğun kullandığını açıklamaktadır.

3. METADOLOJİ: SINIFLANDIRMA VE ÇAPRAZ DOĞRULAMA

Bu bölüm, kullanılan algoritmaları, model seçimi aşamalarını ve hiperparametre optimizasyonu adımlarını detaylandırmaktadır.

3.1. Çapraz Doğrulama ve Veri Bölümlemesi

Veri seti, aşırı öğrenmeyi (Overfitting) test edebilmek amacıyla rastgelelik (random_state=42) korunarak %80 Eğitim (Train) ve %20 Test (Test) olacak şekilde (train_test_split) ikiye ayrılmıştır. Modelin eğitim sürecinde yalnızca eğitim setindeki varyanslar dikkate alınmış, performans değerlendirmesinde ise modelin daha önce hiç görmediği test verileri kullanılmıştır.

3.2. Kullanılan Makine Öğrenmesi Modelleri

Proje kapsamında performansı en iyi seviyeye çıkarmak için farklı paradigmalara sahip pek çok sınıflandırma algoritması test edilmiştir:

Kullanılan Model	Açıklama ve Kullanım Nedeni
Lojistik Regresyon	Doğrusal ilişkileri temel alarak sınıflandırma yapar. Veri setindeki temel baseline (taban) başarıyı ölçmek için kullanılmıştır.
K-En Yakın Komşu (KNN)	Uzaydaki mesafelere göre sınıf ataması yapan uzaklık tabanlı bir modeldir. k=5 olarak belirlenmiştir.
Destek Vektör Makineleri (SVM)	RBF (Radial Basis Function) çekirdeği kullanılarak karmaşık, doğrusal olmayan karar sınırları oluşturulmuştur.
Ağaç Tabanlı Modeller	Karar Ağaçları, Random Forest ve Extra Trees Classifier kullanılarak bilginin parçalanması ile sağlam sınıflandırmalar elde edilmiştir.
Topluluk (Ensemble) Modelleri	BaggingClassifier ve özellikle XGBoost (Extreme Gradient Boosting) gibi güçlü ağaç yapılarıyla hataları optimize eden algoritmalar tercih edilmiştir.

3.3. XGBoost ve Hiperparametre Optimizasyonu

Tabular (tablo) verilerindeki üstün performansı sebebiyle ana tahminleyici olarak XGBoost Classifier belirlenmiştir. Modelin performansı daha da artırmak için GridSearchCV ile kapsamlı bir hiperparametre optimizasyonu (Tuning) yapılmıştır. N-estimators (ağaç sayısı), max_depth (maksimum derinlik) ve learning_rate (öğrenme katsayısı) gibi kilit parametreler optimize edilerek model en iyi formuna getirilmiş, overfitting ve underfitting riskleri dengelenmiştir.

4. PROGRAMIN TEST EDİLEBİLİRLİĞİ VE ARAYÜZ

Makine öğrenmesi modellerinin sadece kod hücrelerinde kalmaması ve pratik hayata entegre edilebilmesi için Python tabanlı Streamlit kütüphanesi kullanılarak bir web arayüzü tasarlanmıştır.

Arayüzde oluşturulan yan menüler ve veri giriş alanları sayesinde kullanıcı kendi demografik verilerini (yaş, boy, kilo) ve yaşam tarzı alışkanlıklarını sisteme girmektedir. Sistem arka planda, daha önceden joblib ile diske kaydedilmiş olan xgboost_obezite_model.pkl, scaler.pkl ve diğer dönüşüm objelerini (LabelEncoder) belleğe alır. Girilen yeni veriler, eğitim aşamasında kullanılan standart ölçeklendirme ve One-Hot encoding adımlarından eş zamanlı olarak geçer. Model, olasılık dağılımını (predict_proba) kullanarak girilen profilin hangi obezite kategorisinde olma ihtimalini yüzdesel dilimlerle (Örn: %85 Obezite Tip 2, %15 Obezite Tip 1) sunarak detaylı bir şeffaflık (Explainability) sağlar.


5. DENEYSEL SONUÇLAR VE PERFORMANS METRİKLERİ

Eğitilen modeller test verisi üzerinde denenmiş ve kapsamlı metrikler elde edilmiştir. Modelin sonuçları Accuracy (Doğruluk), Precision (Hassasiyet), Recall (Duyarlılık) ve bu değerlerin harmonik ortalaması olan F1 Skoruna göre analiz edilmiştir.

5.1. Performans Analizi

Optimizasyon süreci tamamlanmış XGBoost modelinin temel performans metrikleri aşağıdadır:

- **Veri Seti Boyutu:** Toplam 20.758 örnek üzerinden eğitim ve test gerçekleştirilmiştir.
- **Doğruluk (Accuracy):** Test verisi üzerinde %87.16 seviyesinde genel doğruluk oranına ulaşılmıştır.
- **F1-Skoru:** Sınıflar arası dengesizlikler dikkate alındığında %87.15 gibi yüksek bir F1 skoruna imza atılmıştır. Bu durum, modelin sadece çoğunluk sınıflarında değil, tüm obezite sınıflarında dengeli ve isabetli tahminler ürettiğini kanıtlamaktadır.




Grafik 3 Test verisi üzerinde modelin elde ettiği karmaşıklık matrisi

Bu matris, modelin hangi obezite sınıflarını çok iyi tahmin ettiğini, hangilerinde ise (örneğin Fazla Kilo Tip 1 ile Tip 2 arasında) ufak karışıklıklar yaşadığını göstermektedir. Ana köşegen (diyagonal) üzerindeki koyu renkli ve yüksek değerler, modelimizin yüksek doğruluk oranını görsel olarak kanıtlamaktadır.

5.2. Özelliklerin Etki Derecesi (Feature Importance)

Modelin karar mekanizmaları incelendiğinde, obezite risk seviyesini belirleyen en kritik özniteliklerin şunlar olduğu saptanmıştır:

- BMI (Vücut Kitle İndeksi): Sınıflandırmada açık ara en ayırt edici olan faktördür.
- Yaş (Age): Metabolizma hızının değişimi ve yaşam tarzının evrimini temsil ettiği için modelin tahminlerinde ikincil büyük ağırlığa sahiptir.
- Sebze Tüketimi (FCVC): Beslenme kalitesini doğrudan etkilediğinden, model kararlarında güçlü bir pozitif/negatif korelasyon çarpanıdır.
- Teknoloji Kullanım Süresi (TUE) ve Fiziksel Aktivite (FAF): Hareketsiz yaşam tarzını yansıtan bu metrikler modelin riskli grupları tespitinde yüksek ağırlığa sahiptir.



Grafik 4 Özelliklerin etki derecesi

6. SONUÇ

Gerçekleştirilen bu projede, ham yaşam tarzı ve beslenme verilerinden hareketle ileri düzey makine öğrenmesi teknikleriyle güvenilir bir teşhis/öneri asistanı inşa edilmiştir. Değişken analizlerinden ve hiperparametre optimizasyonlarından başarıyla geçen XGBoost modeli, obezite sınıfları arasında %87'nin üzerinde bir kesinlikle doğru atama yapabilme kabiliyetini ispatlamıştır. Geliştirilen bu uygulama Streamlit altyapısıyla harmanlanarak projenin akademik sınırların dışına çıkıp doğrudan kullanıcılara değer üreten uçtan uca, şeffaf bir dijital sağlık aracına dönüşmesini sağlamıştır.

7. KULLANILAN KAYNAKLAR VE PROJE SORUMLULARI

Veri Seti: <https://www.kaggle.com/code/chinmayadatt/obesity-risk-prediction-multi-class-0-92160>

Sorumlular:

Ayşe YENİBAĞCI - 234210067

Shafiqullah QASEMİ - 234210001

Safa KAYALAR - 234210044